08MIAR-Aprendizaje por refuerzo

Sesión 3 – Algoritmos base: Deep Q-Network

Curso Octubre 22/23

Universidad Internacional de Valencia

23/05/2023

De:
Planeta Formación y Universidades

Índice

Índice

¿Dónde estamos?

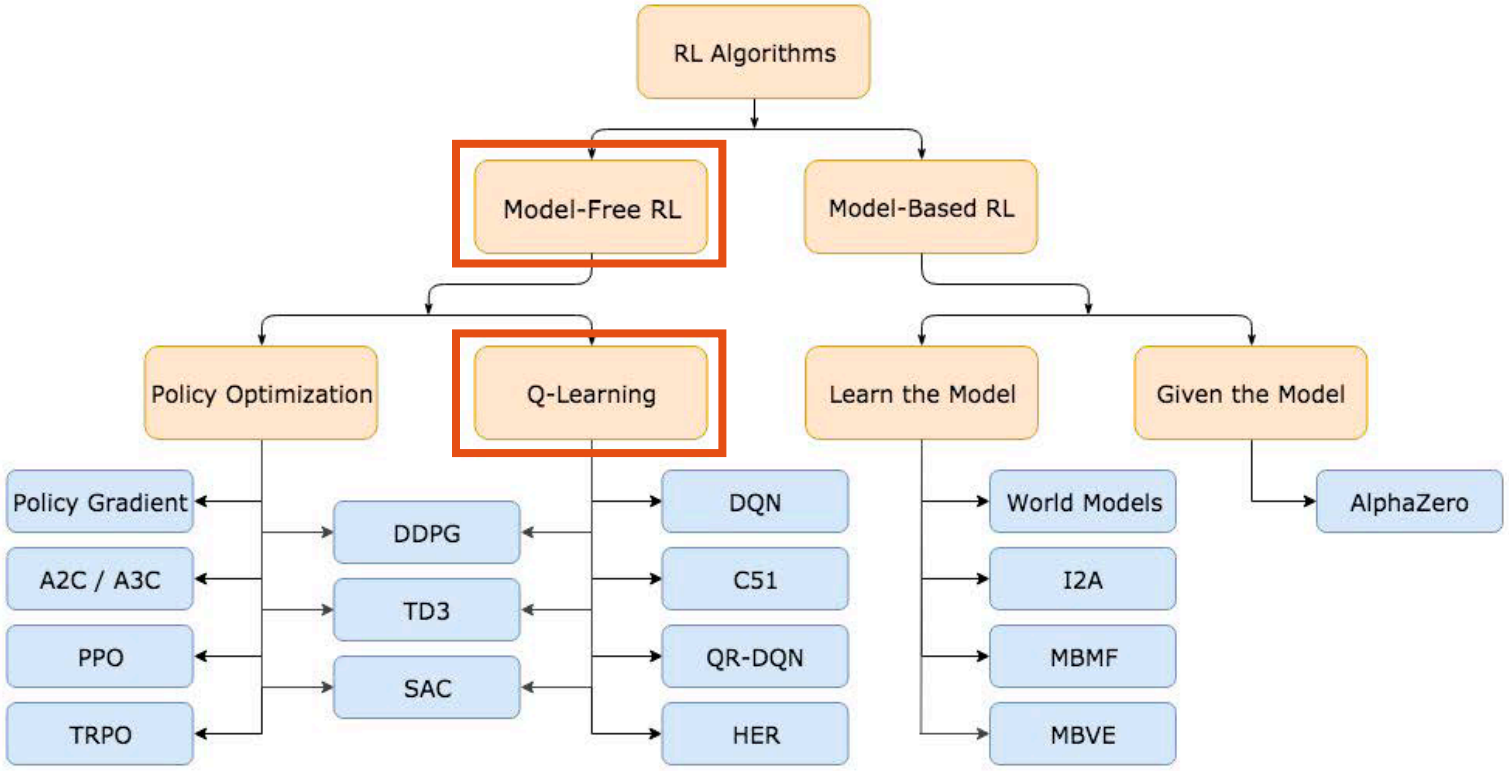

Finite Markov Decision Process

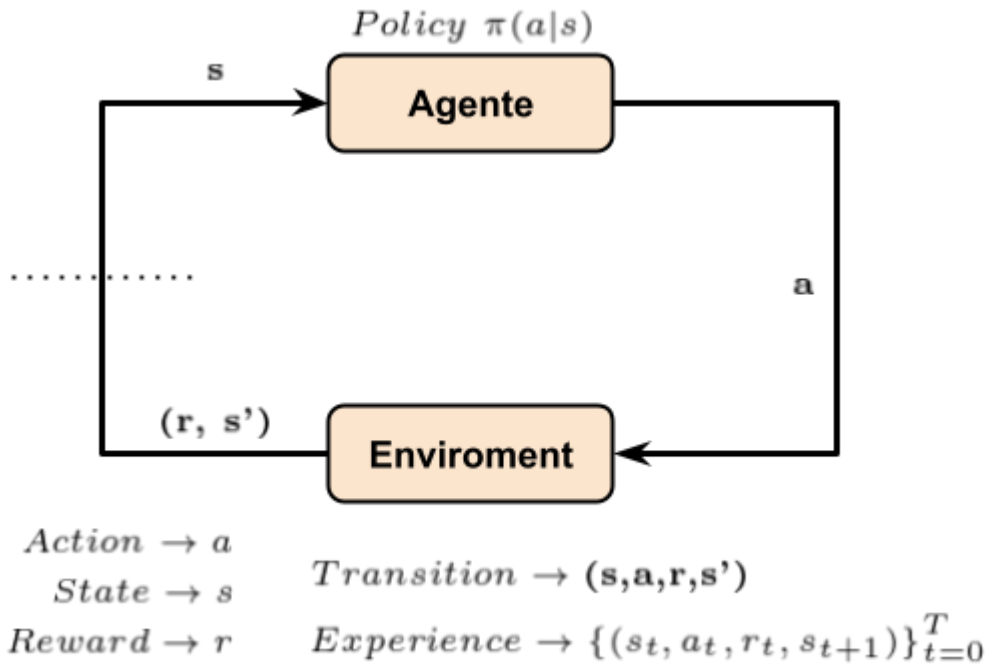

- **Finite MDPs: ($\mathcal{S}$, $\mathcal{A}$) son espacios finitos.**
- ***Markov property***: La probabilidad de cada valor posible para s' depende del estado y la acción inmediatamente anteriores.
- El **estado** debe incluir información sobre todos los **aspectos relevantes de la interacción agente-entorno en el pasado**.

¿Cómo de buena es una policy?

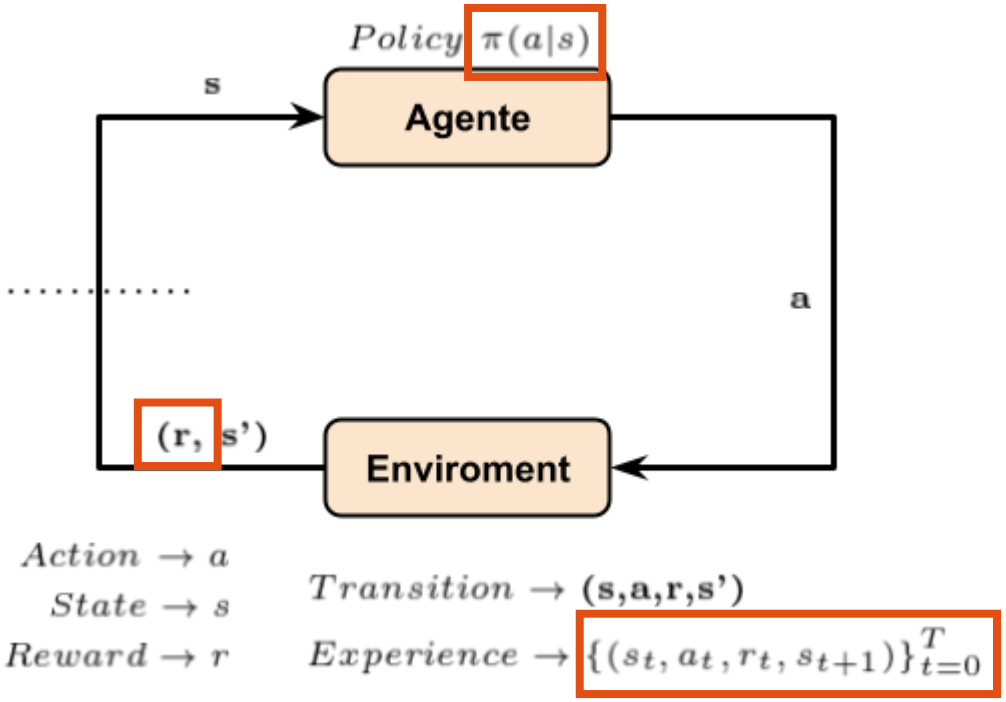

- Una **policy,** $\pi(a|s)$, es una función de **mapeo de estados a probabilidades sobre acciones**.
- El **objetivo** del agente es **maximizar la recompensa acumulada a futuro**.

$$G_t = r_{t+1} + r_{t+2} + r_{t+2} + \ldots + r_T$$

- ***Discounted reward***: *discount factor* $0 \leq \gamma \leq 1$.

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

- Propiedad de **recursividad**: $G_t = r_{t+1} + \gamma G_{t+1}$

Valor y calidad de un estado

- **Función value,** $v_\pi(s)$. La función estado-valor de un estado, s, **bajo una policy** π, es la **recompensa esperada a futuro** comenzando en s, y siguiendo la policy desde entonces.

$$v_\pi(s) = E_\pi[G_t|s] = \sum_a \pi(a|s) \cdot r_{t+1} + v_\pi(s')$$

- ***Quality*, $q_\pi(s,a)$.** La función calidad de tomar la acción a, en estado s, bajo una , **bajo una policy π, es la recomensa esperada a futuro,** comenzando en s, tomando la acción a, y a continuación siguiendo la policy.

$$q_\pi(s,a) = E_\pi[G_t|(s,a)] = \{ r_{t+1} + v_\pi(s') \}_a$$

Q-learning

- ***Política óptima,*** π^****.*** Aquella estrategia que, siguiéndola, nos devuelve la **máxima recompensa esperada a futuro**. Se suele seguir una **política voraz** ***(greedy)****, respecto a* $\boldsymbol{q_\pi(s,a)}$.

$$\pi^*(s) = argmax_a\ (q^{\pi^*}(s,a))$$

- **Ecuación de Bellman**. El objetivo entonces es **encontrar la función** $\boldsymbol{q}$ **óptima** para tu problema, y luego seguir una política voraz sobre dicha función. La ecuación de Bellman proporciona una **definición recursiva** con la que podremos encontrar la función óptima q.

$$q^{\pi^*}(s,a) = r + \gamma max_{a'} q^{\pi^*}(s',a')$$

Índice

Gridworld

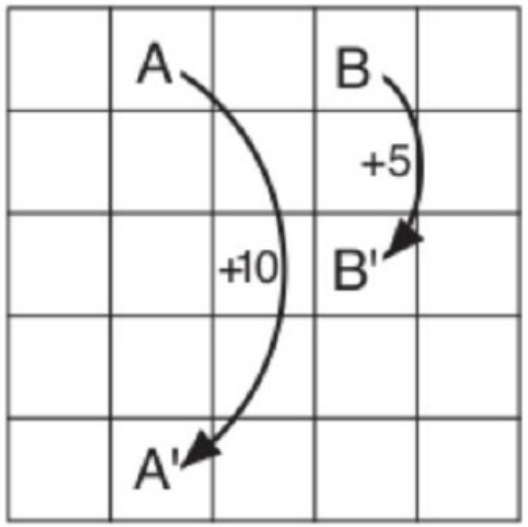

Gridworld de *Sutton & Barto, Capítulo 3*

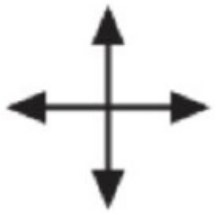

Actions

Gridworld de *Sutton & Barto, Capítulo 3*

- Las **celdas** corresponden con los **estados** del entorno.

- La recompensa para cada acción-estado es:
  - **+10** para la transición de **A a A'** (que es la única acción que se puede ejecutar en A).
  - **+5** para la transición de **B a B'** (que es la única acción que se puede ejecutar en B).
  - **-1** si el movimiento se sale del *grid.*
  - **0** en cualquier otro caso.

Random policy evaluation

- Originalmente, la estimación de q se realiza por medio de **programación dinámica**, de forma **iterativa**. De esta forma, se define una **política aleatoria**, y se realiza una exploración del entorno actualizando la función v en base a la experiencia.

- Política aleatoria, $\pi^r(s|a) = 1/A$.

i) Inicialización $v_\pi(s)$

```
array([[0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.]])
```

ii) Exploración iterativa

- Comenzamos en s=[0,0]. Para cada acción:

  - Arriba: `0.25 * (-1 + 0.9 * 0) = -0.25`
  - Abajo: `0.25 * (0 + 0.9 * 0) = 0`
  - Derecha: `0.25 * (0 + 0.9 * 0) = 0`
  - Izquierda: `0.25 * (-1 + 0.9 * 0) = -0.25`

$$v_\pi(s) = E_\pi[G_t|s] = \sum_a \pi(a|s) \cdot r_{t+1} + v_\pi(s') = -0.5$$

- Repetir para cada **iteración k, para todo s,** y actualizar la función value tras cada iteración $v_\pi(s)$

Exploración iterativa

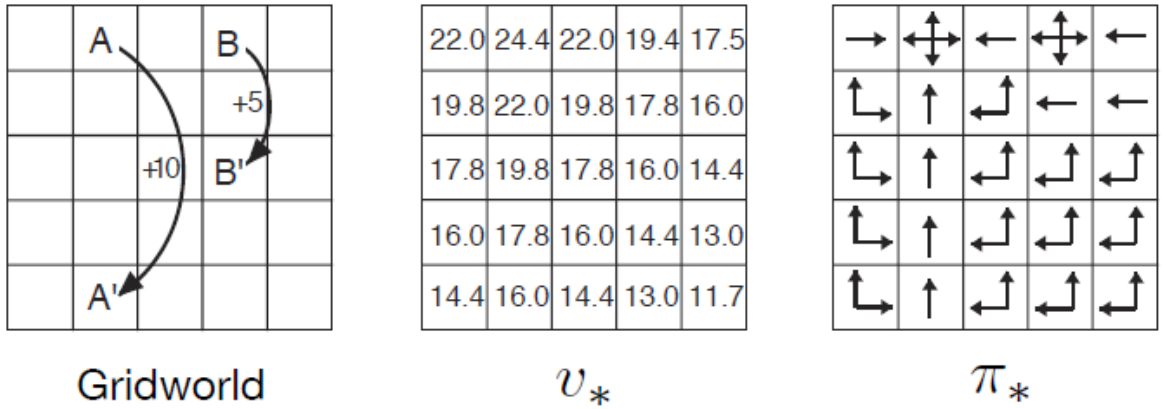

Figure 3.5: Optimal solutions to the gridworld example.

Gridworld de *Sutton & Barto, Capítulo 3*

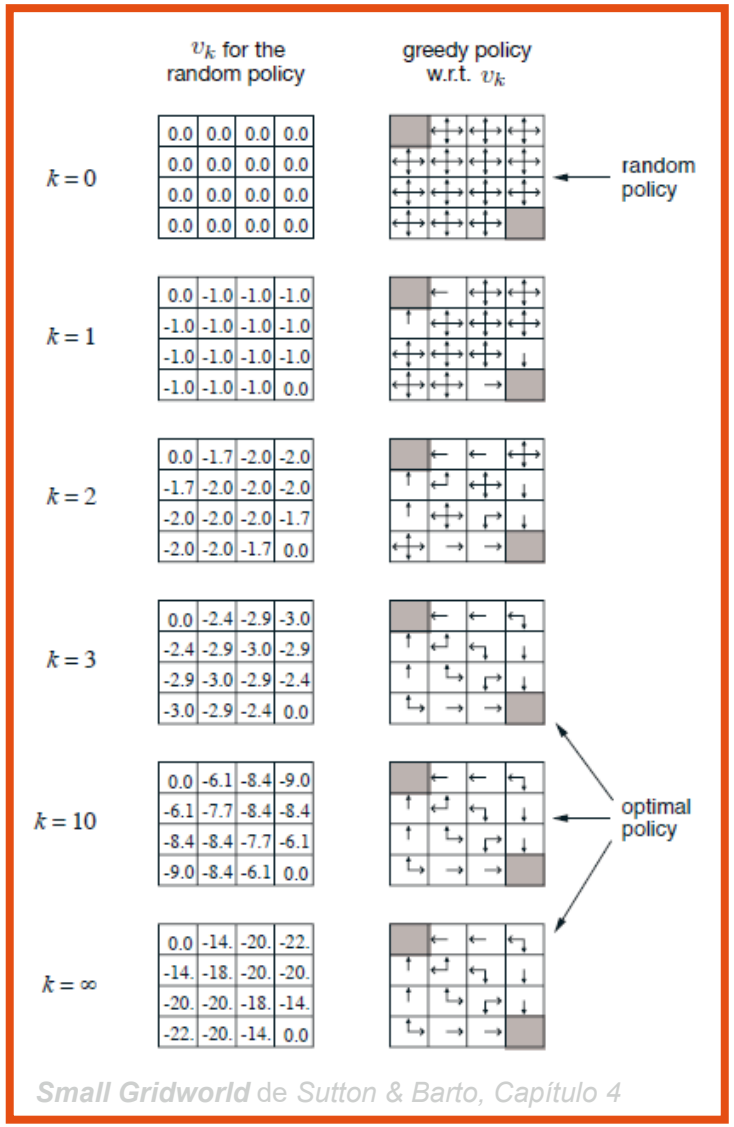

Small Gridworld de *Sutton & Barto, Capítulo 4*

Exploración iterativa

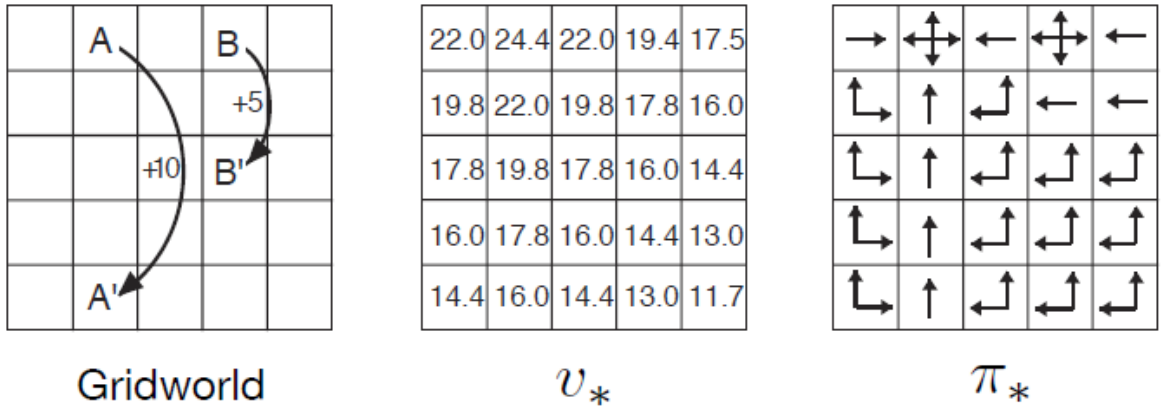

Figure 3.5: Optimal solutions to the gridworld example.

Gridworld de *Sutton & Barto, Capítulo 3*

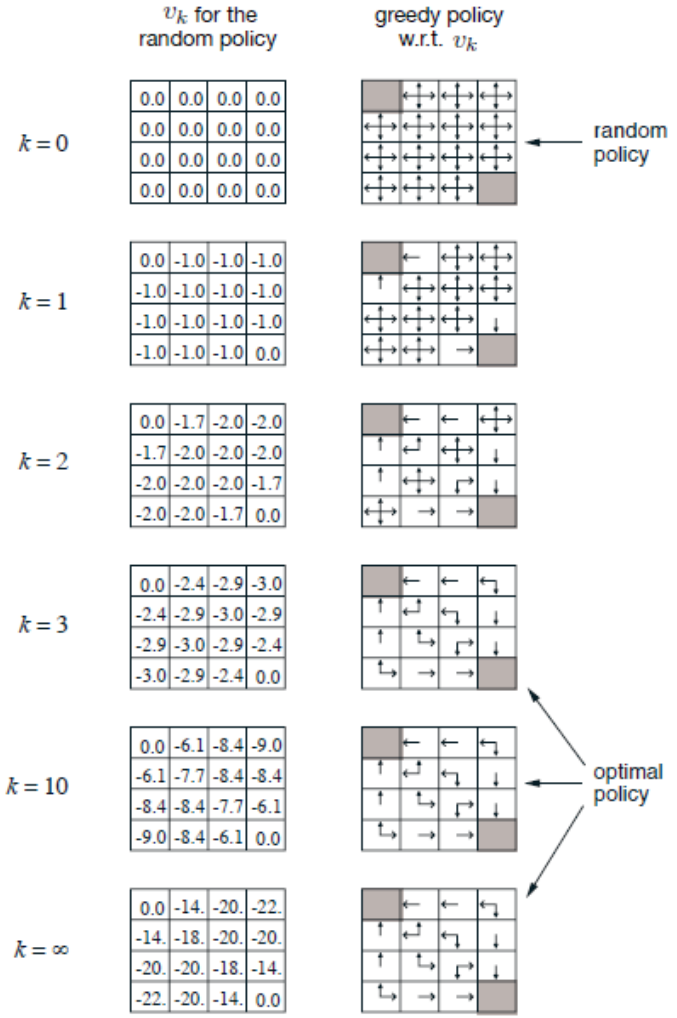

Small Gridworld de *Sutton & Barto, Capítulo 4*

Índice

Deep Q-network

- Asunciones en ***Finite MDPs*** **: ($\mathcal{S}$, $\mathcal{A}$) son espacios finitos.**
- En escenarios prácticos, la **dimensionalidad** del espacio de **estados y acciones** hace **intratable** esta evaluación iterativa.
- Uso de una **DNN,** $f_\theta(\cdot)$, como función **aproximadora** de $q^{\pi^*}(s,a)$.

$$\pi^*(s) = argmax_a \left(q^{\pi^*}(s,a)\right) = argmax_a \left(f_\theta(s)\right)$$

- Debido a que la mayoría de las simulaciones trabajan con la pantalla directamente, el tipo de red neuronal que usaremos serán **redes convolucionales**.

Deep Q-network

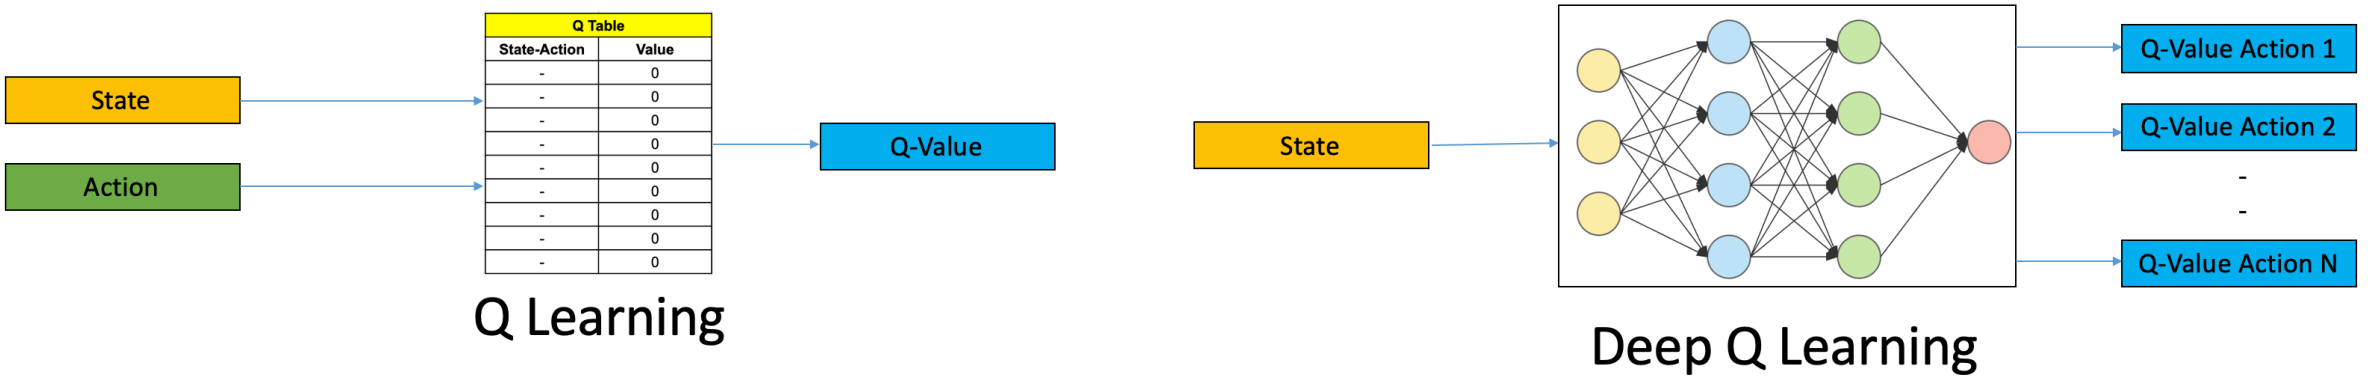

https://cdn.analyticsvidhya.com/wp-content/uploads/2019/04/Screenshot-2019-04-16-at-5.46.01-PM.png

Índice

Proceso de aprendizaje

- Uso de **Bellman** como función aproximadora en nuestro proceso de aprendizaje.

$$q(s,a) = r + \gamma max_a q(s', a\ )$$

- Considerando que $q(s,a)$ como una red neuronal, $f_\theta(\cdot)$, se puede definir una **función de coste** en base a las **diferencias temporales**, y optimizar la red neuronal en base a la tupla $(\boldsymbol{s}, \boldsymbol{a}, \boldsymbol{r}, \boldsymbol{s'})$ de cada iteración por **descenso de gradiente**. Como función de pérdidas, el error cuadrático suele ser la solución base.

$$q(s,a) \rightarrow r + \gamma max_a q(s', a\ )$$

$$\boldsymbol{L} = (\boldsymbol{r} + \gamma max_{\boldsymbol{a}} q(\boldsymbol{s'}, \boldsymbol{a}\ )) - q(\boldsymbol{s}, \boldsymbol{a}))^2$$

Proceso de aprendizaje

- El uso de una **red neuronal para estimar la función $q(s,a)$ no asegura convergencia a la $q^{\pi^*}(s,a)$**. Es un **proceso inestable**, con tendencia a llegar a **mínimos locales**. Se han desarrollado una serie de **estrategias** para aliviar esto:

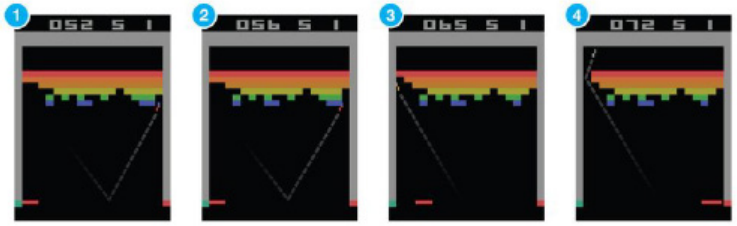

  - **Series temporales**.
  - **Exploración**. Se sigue una política ε-greedy para evitar sobreajuste.
  - ***Experience replay***. En la experiencia se almacenan tuplas (s,a,r,s') obtenidas con versiones antiguas de la red $q(s,a)$.
  - **Target network**. En la función de coste se sustituye la $q(s,a)$ del siguiente estado por una versión anterior de la red neuronal, llamada target network, $\hat{q}(s',a)$. That is: $q(s,a) \rightarrow r + \gamma max_a \hat{q}(s',a)$.
  - **Error clipping**. Evitar actualizaciones demasiado altas. Se suele utilizar la función de Huber.

$$Huber(a) = \begin{cases} \frac{1}{2}a^2 & \text{for } |a| \leq 1, \\ (|a| - \frac{1}{2}), & \text{otherwise.} \end{cases}$$

Por qué DQN es off-policy?

- **DQN** es el principal exponente de la familia de métodos conocidos cómo ***off-policy***. Pero, ¿a qué se refiere este tipo de aprendizaje? Os encontraréis dos interpretaciones en la literatura:
    - Basada en **Exploración.** Al seguir una **política ε-greedy**, la política que tratamos de predecir como **política objetivo (voraz, greedy)** no se corresponde con la que nuestro agente está siguiendo.
    - Basada en ***Experience replay.*** Al acumular en la **experiencia** tuplas (s, a, r, s') **de antiguas iteraciones**, la red es actualizada con políticas que no se corresponden con la actual.
- La opción más aceptada en la literatura es la segunda, basada en la **clasificación de estrategias de aprendizaje centrada en el uso de la memoria**.

Índice

Algoritmo DQN

Algorithm 1 Deep Q-learning with Experience Replay

Initialize replay memory $\mathcal{D}$ to capacity N
Initialize action-value function Q with random weights
for episode $= 1, M$ **do**
  Initialise sequence $s_1 = \{x_1\}$ and preprocessed sequenced $\phi_1 = \phi(s_1)$
  for $t = 1, T$ **do**
    With probability ϵ select a random action a_t
    otherwise select $a_t = \max_a Q^*(\phi(s_t), a; \theta)$
    Execute action a_t in emulator and observe reward r_t and image x_{t+1}
    Set $s_{t+1} = s_t, a_t, x_{t+1}$ and preprocess $\phi_{t+1} = \phi(s_{t+1})$
    Store transition $(\phi_t, a_t, r_t, \phi_{t+1})$ in $\mathcal{D}$
    Sample random minibatch of transitions $(\phi_j, a_j, r_j, \phi_{j+1})$ from $\mathcal{D}$
    Set $y_j = \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \gamma \max_{a'} Q(\phi_{j+1}, a'; \theta) & \text{for non-terminal } \phi_{j+1} \end{cases}$
    Perform a gradient descent step on $(y_j - Q(\phi_j, a_j; \theta))^2$ according to equation 3
  end for
end for

Playing Atari with Deep Reinforcement Learning (https://arxiv.org/abs/1312.5602)

Índice

Conclusiones

- Hemos estudiado el primero de los algoritmos base que veremos en la asignatura, **DQN**. Este algoritmos pertenece a la familia de **métodos *off-policy***.

- Está basado en **Q-learning**, donde el objetivo es **estimar la recompensa** esperada para cada par **estado/acción**.

- **DQN combina Q-learning con arquitecturas de Deep Learning**, para poder abarcar problemas con **espacios** de **dimensiones muy grandes**

- Algunas variaciones, necesarias para la convergencia de la solución, en la versión final del algoritmo de DQN son el uso de una **target network** y de **secuencias de frames** como datos de entrada del modelo del agente.

Índice

Bibliografía recomendada

- Human level control through Deep Reinforcement learning, Google Deepmind *https://deepmind.com/research/publications/2019/human-level-control-through-deep-reinforcement learning*

- An Introduction to Q-learning: Reinforcement Learning, Sayak Paul, Floydhub *https://blog.floydhub.com/an-introduction-to-q-learning-reinforcement-learning/*

Universidad Internacional de Valencia

universidadviu.com

De:
Planeta Formación y Universidades